Informationsblatt: Datenaufbereitung

1. Einleitung

Jedes System, sei es ein Warenwirtschaftssystem, Shopsystem oder Analysetools wie Google Analytics und der Gleichen, nutzt Daten. Doch wenn es darum geht das alle Systeme reibungslos miteinander agieren können, gibt es eine Schwierigkeit: das Datenformat. Nur weil man alle Daten vom Hersteller in einer Excel-Tabelle bekommt, heißt das noch lang nicht das man diese Excel dann einfach in Shopsystem hochladen kann.

Sogenannte Rohdaten müssen deshalb mit großem Zeiteinsatz, formatiert und richtig strukturiert werden, damit sie Ihren Zweck erfüllen. Sie sind wie Legosteine - nur kann man sie noch nicht aufeinander stecken, da sie noch einige Unebenheiten aufweisen.

2. Prozess

Um relevante Daten für einen Anwendungsfall aufzubereiten sin folgende Schritt von Nöten:

1. **Sammlung & Ermittlung der Daten** (Welche Daten haben wir schon? Welche Daten müssen wir noch sammeln, damit wir sie in einen Zusammenhang bringen können?)
2. **Bereinigung & Prüfung der Daten** (Welche Daten sind Ausreißer/irrelevant? Welche Daten sind fehlerhaft? Welche Daten fehlen noch?)
3. **Formatierung und Anreicherung der Daten** (Welche Formatierung sollen die Daten haben? Welche externen Datensätze müssen wir noch anfügen, um ein relevanter Zusammenhang zu erzeugen?)
4. **Speicherung / Verwendung der Daten** (Daten zur Auswertung des Anwendungsfalls verwenden bzw. einfach abspeichern für später)

3. Problem

Wie schon in der Einleitung erwähnt ist eines der größten Probleme beim Aufbereiten von Daten das Format der Daten. Ein gutes Beispiel für die Formatierung von Daten ist wohl ein Datum. Das gleiche Datum kann auf viele verschiedene Art & Weisen formatiert sein:

	A	B	C	D
1	11.06.18	Montag, 11. Juni 2018	11.06.2018	2018-06-11

Bespiel für Formatierung: Datum

Dieses Problem muss jetzt mit einem Makro bzw. einer API gelöst werden, die das Datum (in unserem Bespiel) in die passende Formatierung bringt. Damit am Ende eines solchen Prozesses die Daten in einem realistischen Rahmen sind, wird noch ein Algorithmus verwendet, der z.B. Alarm schlägt, wenn der formatierte Kaufpreis unter einem bestimmten Wert liegt. Damit wird verhindert, dass der Kaufpreis nicht durch die Formatierung einen neuen Wert trägt. Zum Beispiel weil das Komma um eine Stelle zu weit links platziert wurde. Dieser Prozess nennt sich „Datenvalidierung“.

3.1 Data Warehouse

Ein Data Warehouse (kurz „DWH“) ist genau das was an vermuten würde. Dort werden alle Daten z.B. eines ganzen Unternehmens gespeichert und gepflegt. Natürlich sind nur bereits aufbereitete Daten enthalten. Das „DHW“ ermöglicht eine globale Sicht auf die Daten, da diese aus vielen verschiedenen heterogenen Quellen eingespielt und zusammengetragen werden.

4. Lösungen, Anbieter und Tools

Große Anbieter für diesen Bereich sind „improvado“, „alteryx“, „Microsoft Power BI“ und „tableau prep“. Viele arbeiten mit KI-Lösungen die bei der Datenaufbearbeitung enorm Zeit sparen.

Quellen: https://www.bigdata-insider.de/was-ist-ein-data-warehouse-a-606701/; https://www.talend.com/de/resources/what-is-data-preparation/; https://improvado.io/blog/data-preparation-tools;

Aufgabenblatt

1. Was ist der wichtigste Aspekt bei der Datenaufbereitung?

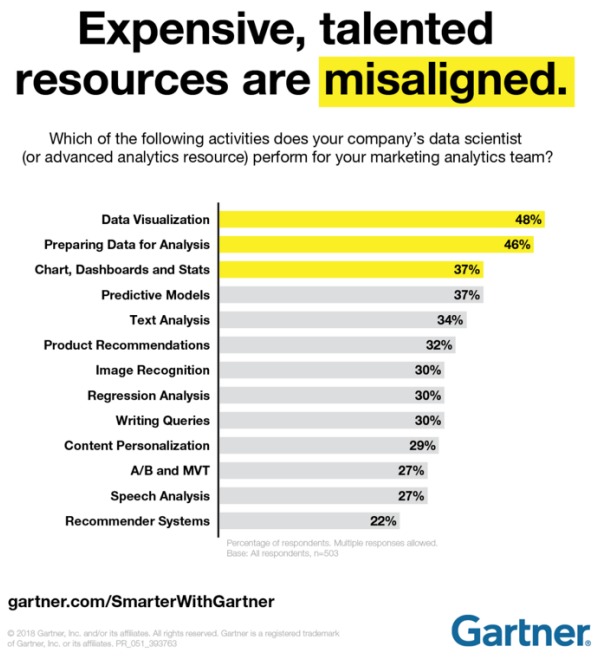
a) Datengröße
b) Datenformat
c) Datenfrequenz

2. Sie wollen Ihre Produkte bei Idealo.de anbieten. Aus dem Hilfecenter erfahren sie leider kaum wie Ihr Datenfeed (ähnlicher Aufbau wie eine Excel-Tabelle) aufgebaut sein soll. Was müssen sie den Support-Mitarbeiter fragen? (2 Antworten)

3. Beschreibe sie das Problem mit folgender Formatierung von Kundendaten, die Ihnen ein Kollege zum einpflegen als Excel-Tabelle schickt:

	A	B	C	D
1	**Kunde**	**Adresse**	**Produkt gekauft**	**Anzahl**
2	Hannes Hensel	Gretelstraße 12 17450 Hammeln	Produkt A2	3
3	Lina Lustig	Pusteweg 345 38628 Dinnheim	Produkt B3	4
4	Peter Panne	Landstraße 1 11123 Dummdorf	Produkt B1	6
5	Aaron Amen	Große Straße 55 76444 Krümeln	Produkt C4	8
6	Malte Malz	Alter Platz 69 69696 Lusten	Produkt A1	2
7	Kriss Kunde	Waldschulweg 123 45678 Hansdorf	Produkt C2	11

4. Lese die Studie von Gartner und erläutere warum es so wichtig für ein Unternehmen wichtig ist seine Daten aufzubereiten!



Quellen: https://www.bigdata-insider.de/was-ist-ein-data-warehouse-a-606701/; https://www.talend.com/de/resources/what-is-data-preparation/; https://improvado.io/blog/data-preparation-tools;

Lösungsblatt

1. Was ist der wichtigste Aspekt bei der Datenaufbereitung?

a) Datengröße
b) Datenformat
c) Datenfrequenz

2. Sie wollen Ihre Produkte bei Idealo.de anbieten. Aus dem Hilfecenter erfahren sie leider kaum wie Ihr Datenfeed (ähnlicher Aufbau wie eine Excel-Tabelle) aufgebaut sein soll. Was müssen sie den Support-Mitarbeiter fragen? (2 Antworten)

a) Welche Produktedaten brauchen sie von uns und in welcher Reihenfolge sollen sie in der Excel angeordnet sein?
b) Welche Formatierungen sollen die jeweiligen Daten haben?

3. Beschreibe sie das Problem mit folgender Formatierung von Kundendaten, die Ihnen ein Kollege zum einpflegen als Excel-Tabelle schickt:

	A	B	C	D
1	**Kunde**	**Adresse**	**Produkt gekauft**	**Anzahl**
2	Hannes Hensel	Gretelstraße 12 17450 Hammeln	Produkt A2	3
3	Lina Lustig	Pusteweg 345 38628 Dinnheim	Produkt B3	4
4	Peter Panne	Landstraße 1 11123 Dummdorf	Produkt B1	6
5	Aaron Amen	Große Straße 55 76444 Krümeln	Produkt C4	8
6	Malte Malz	Alter Platz 69 69696 Lusten	Produkt A1	2
7	Kriss Kunde	Waldschulweg 123 45678 Hansdorf	Produkt C2	11

- Die Adressangaben und Namen der Kunden sind nicht einzeln aufgelistet (eine Info p Zelle (Vorname: Hannes / Nachname: Hensel / Straße: Gretelstraße / Hausnummer: 12 / usw.)

4. Lese die Studie von Gartner und erläutere warum es so wichtig für ein Unternehmen wichtig ist seine Daten aufzubereiten!

- Data-Wissenschaftler in vielen Unternehmen verwenden viel Zeit auf Datenaufbereitung statt auf die Bildung von relevanten Einblicken, die dem Unternehmen wirtschaftlich weiterhelfen

Quellen: https://www.bigdata-insider.de/was-ist-ein-data-warehouse-a-606701/; https://www.talend.com/de/resources/what-is-data-preparation/; https://improvado.io/blog/data-preparation-tools;